Правительство Российской Федерации
Национальный исследовательский университет
«Высшая школа экономики» — Москва, Санкт-Петербург

Факультет экономических наук
Департамент статистики и анализа данных

Модульная работа №2
на тему:

«Построение деревьев классификации и расщепление смеси»

выполнили: **Дудин Дмитрий Сергеевич,**
Кузьмин Андрей Владиславович,
Кутузова Алина Сергеевна,
Редькина Любовь Александровна,

проверил: **Прокопенко С. В.**
учебный ассистент

Москва, Санкт–Петербург
2026

СОДЕРЖАНИЕ

Этап 1: Описание цели и гипотез; подготовка данных.....2
Этап 2: Дискриминантный анализ.....6
Этап 3: Дискриминантный анализ.....15
Этап 4: Расщепление смеси.....20

Этап 1: Описание цели и гипотез; подготовка данных

Описание требований:

1. Описать цели и гипотезы исследования;
2. Описать данные и их структуру;
3. Определить категориальную переменную в качестве целевой для дискриминантного анализа и деревьев решений.

Использованное ПО: SPSS

В настоящем исследовании используются данные, прежде уже примененные в рамках *модульной работы №1*. Поэтому, с учетом выводов, полученных в результате выполнения предыдущей работы, цель и задачи для данного исследования представляются следующими:

1. ***Целью*** настоящего исследования является выявление факторов, детерминирующих принадлежность российских образовательных организаций высшего звена к различным по качеству группам на основе показателя среднего балла ЕГЭ абитуриентов. Кроме того, данная работа также исследует возможность классификации образовательных учреждений на основе их финансовых, кадровых и инфраструктурных показателей.
2. ***Объектом*** настоящей работы являются 116 российских учреждений высшего образования, для которых приводятся следующие характеристики:
   2.1. Средний балл ЕГЭ студентов, принятых по результатам ЕГЭ на обучение по очной форме по программам бакалавриата и специалитета за счет средств соответствующих бюджетов бюджетной системы РФ *(здесь и при работе в SPSS приведен как «EGE_score»)* — *в баллах ЕГЭ*, показатель непрерывен;
   2.2. Доходы образовательной организации из всех источников в расчете на численность студентов *(здесь и при работе в SPSS*

приведен как «INCOME_per_capita») — *в тыс. рублей на студента*, показатель непрерывен;

2.3. Общая численность докторантов *(здесь и при работе в SPSS* приведен *как «DOC_num»)* — *в ед. человек*, показатель дискретен;

2.4. Средняя заработная плата ППС (без внешних совместителей и работающих по договорам ГПХ) *(здесь и при работе в SPSS приведен как «SALARY_mean»)* — *в тыс. рублей*, показатель непрерывен;

2.5. Площадь общежитий *(здесь и при работе в SPSS приведен как «DORMS_space»)* — *в м. кв.*, показатель дискретен;

2.6. Число предприятий, являющихся базами практики с которыми оформлены договорные отношения *(при работе в SPSS приведен как «PARTNERS_num»)* — *в ед. предприятий*, показатель дискретен.

Кроме того, на основе показателя среднего балла ЕГЭ *по терцилям распределения* была сформирована категориальная переменная, которая станет целевой для последующего анализа — «EGE_category». В результате были выделены группы с низким, средним и высоким уровнем ЕГЭ поступающих.

3. ***Гипотезами*** настоящей работы представляются следующие предположения:

3.1. Существуют статистически значимые различия в уровне доходов образовательных организаций между группами ВУЗов с различным уровнем среднего балла ЕГЭ поступающих;

3.2. Существуют статистически значимые различия в уровне заработной платы преподавателей образовательных организаций между группами ВУЗов с различным уровнем среднего балла ЕГЭ поступающих;

3.3. Финансовые показатели (доходы и заработная плата ППС) образовательных организаций вносят наибольший вклад (по сравнению с другими показателями кадрового и инфраструктурного характера) в формирование групп вузов по уровню среднего балла ЕГЭ;

3.4. На основе совокупности финансовых, кадровых и инфраструктурных показателей возможно построение модели, дающей корректную классификацию образовательных организаций по уровню среднего балла ЕГЭ.

Говоря о получении категориальной переменной, стоит описать произведенные вычисления. С целью получить равноценные по объему группы ВУЗов с низким, средним и высоким уровнем среднего балла ЕГЭ абитуриентов была задействована описательная *терцильная* статистика в ПО SPSS:

Рис. 1: Частотный анализ показателя «EGE_score»:

Статистика

EGE_score

N	Валидные	116
	Пропущенные	0
Процентили	33,33333333	67,45[a]
	66,66666667	74,80

a. Процентили вычисляются из сгруппированных данных.

Частотный анализ показателя «EGE_score» выявил следующие пороговые значения для терцилей: от *наименьшего балла до 67.45* баллов для «низкого» уровня; *от 67.45 баллов до 74.8* баллов для «среднего» уровня; *от 74.8 баллов до наибольшего* балла для «высокого» уровня.

Таким образом, в соответствии с полученными границами, была создана категориальная текстовая переменная «EGE_category». Соответствующие значения категорий («низкая», «средняя» и «высокая») были присвоены для каждого из наблюдений на основе разбиения по среднему баллу ЕГЭ абитуриентов с учетом отмеченных выше границ.

Рис. 2: Представление данных в ПО SPSS с новой переменной:

	EDU_name	EGE_score	EGE_cat
1	АДЫГЕЙСКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ	64	низкий уровень
2	АЛТАЙСКИЙ ГОСУДАРСТВЕННЫЙ ПЕДАГОГИЧЕСКИЙ УНИВЕРСИТЕТ	62	низкий уровень
3	АЛТАЙСКИЙ ГОСУДАРСТВЕННЫЙ ТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ ИМ. И.И. ПОЛЗУНОВА	62	низкий уровень
4	АЛТАЙСКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ	70	средний уровень
5	БАЙКАЛЬСКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ	75	высокий уровень
6	БАЛТИЙСКИЙ ФЕДЕРАЛЬНЫЙ УНИВЕРСИТЕТ ИМЕНИ ИММАНУИЛА КАНТА	73	средний уровень
7	БАШКИРСКИЙ ГОСУДАРСТВЕННЫЙ МЕДИЦИНСКИЙ УНИВЕРСИТЕТ МИНИСТЕРСТВА ЗДРАВООХ	78	высокий уровень
8	БЕЛГОРОДСКИЙ ГОСУДАРСТВЕННЫЙ НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ	69	средний уровень
9	БРЯНСКИЙ ГОСУДАРСТВЕННЫЙ ТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ	64	низкий уровень
10	БРЯНСКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ ИМЕНИ АКАДЕМИКА И.Г. ПЕТРОВСКОГО	72	средний уровень
11	БУРЯТСКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ ИМЕНИ ДОРЖИ БАНЗАРОВА	65	низкий уровень
12	ВОЛГОГРАДСКИЙ ГОСУДАРСТВЕННЫЙ АГРАРНЫЙ УНИВЕРСИТЕТ	59	низкий уровень
13	ВОЛГОГРАДСКИЙ ГОСУДАРСТВЕННЫЙ ТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ	63	низкий уровень

Качество разбиения было проверено с помощью частотного анализа. Учитывая, что результат продемонстрировал почти равный уровень частоты для каждой из категорий — 39, 38 и 39 — представляется, что категории на основе показателя «EGE_score» были сформированы верно.

Рис. 3: Частотная статистика для переменной «EGE_category»:

EGE_category

		Частота	Проценты	Валидный процент	Накопленный процент
Валидные	высокий уровень	39	33,6	33,6	33,6
	низкий уровень	38	32,8	32,8	66,4
	средний уровень	39	33,6	33,6	100,0
	Всего	116	100,0	100,0	

Этап 2: Дискриминантный анализ

Описание требований:

1. Выделить 1–3 наиболее удаленных от центров кластеров наблюдения, подлежащих дискриминации;
2. Выполнить дискриминантный анализ;
   - 2.1. Записать выражение для дискриминантной функции;
   - 2.2. Оценить значимость дискриминантной функции по λ Уилкса;
   - 2.3. Определить относительный вклад каждой переменной в формирование классов;
   - 2.4. Определить средние значения дискриминантной функции по группам;
   - 2.5. Указать, к каким группам были отнесены классифицируемые объекты и вероятности, с которыми объекты входят в эти группы;
   - 2.6. Проверить значимость различий средних значений дискриминантной функции в группах;
   - 2.7. Оценить качество дискриминантного анализа и число правильно классифицированных объектов;
   - 2.8. Оценить целесообразность проведения дискриминантного анализа для имеющихся данных.

Использованное ПО: SPSS

Для проведения дискриминантного анализа были выбраны 3 наиболее отклоняющихся наблюдения, каждое из которых характеризуется максимальным расстоянием от центров сформированных кластеров. Выбор данных наблюдений произведен на основе результатов кластерного анализа с использованием встроенного в SPSS метода k–средних с разбиением выборки на три кластера.

Рис. 4: Результаты кластеризации; 3 наблюдения с наибольшим расстоянием от центра кластера:

	ID_alpha	EDU_name	QCL_2
1	115	ЮЖНЫЙ ФЕДЕРАЛЬНЫЙ УНИВЕРСИТЕТ	77921,96355
2	84	САНКТ-ПЕТЕРБУРГСКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ	62406,25185
3	76	РОССИЙСКИЙ УНИВЕРСИТЕТ ДРУЖБЫ НАРОДОВ ИМЕНИ ПАТРИСА ЛУМУМБЫ	60103,77500

Как следует из упорядоченного по убыванию значения удаленности наблюдений от центров кластеров, наибольшие расстояния демонстрируют наблюдения №115, №84 и №76 (номера наблюдений — положение образовательного учреждения в выборке, отсортированной по возрастания параметра с названием ВУЗа). Наибольшие расстояния до центров кластеров составили 77921.96; 62406.25 и 60103.78 условных единиц, что говорит о существенном отличии данных образовательных учреждений от типичных ВУЗов соответствующих кластеров.

Далее был проведен дискриминантный анализ (для соответствующих наблюдений были удалены групповые принадлежности №115 — «средний» уровень, №84 — «высокий» уровень, №76 — также «высокий» уровень). Анализ был произведен по методу принудительного включения с помощью встроенного функционала ПО SPSS; группировка построена по категориальному параметру «NEGE_category_cleared» (данная переменная — аналог «EGE_category», где в технических целях текстовые значения уровней — «низкий», «средний», «высокий» были приравнены к числовым представлениям: 1, 2 и 3 соответственно). Независимыми переменными выступили *стандартизированные* значения исходных переменных: доход ВУЗов («ZINCOME_per_capita»), численность докторантов («ZDOC_num»), заработная плата преподавателей («ZSALARY_mean»), площадь общежитий («ZDORMS_space») и число предприятий–баз практики («ZPARTNERS_num»).

Прежде, чем перейти к описанию выполнения задач, стоит привести интерпретацию полученных групп по их описательной статистике, полученной на ***не***стандартизированных значениях.

Рис. 5: Описательная статистика групп

Статистика группы

Percentile Group of EGE_score		Среднее	Среднекв. отклонение	N валидных (по списку)	
				Невзвешенные	Взвешенные
1	INCOME_per_capita	373,30	155,935	38	38,000
	DOC_num	3,76	4,181	38	38,000
	SALARY_mean	116,96	33,841	38	38,000
	DORMS_space	37263,26	24324,245	38	38,000
	PARTNERS_num	846,89	952,065	38	38,000
2	INCOME_per_capita	388,46	227,277	38	38,000
	DOC_num	6,08	8,897	38	38,000
	SALARY_mean	116,58	40,501	38	38,000
	DORMS_space	58226,66	53631,672	38	38,000
	PARTNERS_num	1222,21	1303,778	38	38,000
3	INCOME_per_capita	717,16	650,945	37	37,000
	DOC_num	9,70	14,592	37	37,000
	SALARY_mean	184,54	60,582	37	37,000
	DORMS_space	67610,08	75936,995	37	37,000
	PARTNERS_num	1078,22	1866,886	37	37,000

Группа 1 представлена ВУЗами с самыми низкими значениями большинства показателей (что ожидаемо — это группа для ВУЗов с наименьшим уровнем среднего балла ЕГЭ абитуриентов). Все значения существенно ниже средних по выборке (так, например, число докторантов составило = 3.7, что почти в 2 раза меньшего среднего, равного 6.5).

Группа 2 представлена ВУЗами промежуточного звена. По сравнению с первой группой они имеют значительно большее число докторантов, более развитую инфраструктуру общежитий и большее число партнеров–баз практик. В то же время, уровень заработной платы преподавателей практически не отличается (для 2–й группы = 116.58, для 1–й группы = 116.96). Таким образом, группа объединяет ВУЗы среднего уровня преимущественно в контексте инфраструктурного обеспечения.

Группа 3 представлена ВУЗами с наиболее высокими значениями по всем показателям, некоторые из которых превышают средние по выборке в 1.5–1.8 раз (например, число докторантов здесь = 9.7, в среднем = 6.5). Таким образом, в группу входят наиболее обеспеченные и научно развитые организации, привлекающие самых конкурентоспособных абитуриентов.

В рамках **задачи 2.1** требовалось получить выражение дискриминантной функции. Эта задача была выполнена: функция имеет вид:

$$D = 0.03 + 0.2\,Z(INCOME) + 0.4\,Z(DOC) + 1\,Z(SALARY) + 0.8\,Z(DORMS) - 0.2\,Z(PARTNERS)$$

Поскольку далее (рис. 6) будет показано, что статистически значима только первая функция, здесь и далее интерпретация результатов дискриминантного анализа приводится только для нее.

Рис. 6: Дискриминантная функция и ее коэффициенты:

Коэффициенты канонической дискриминантной функции

	Функция	
	1	2
Zscore (INCOME_per_capita)	,219	,059
Zscore (DOC_num)	,407	-,386
Zscore (SALARY_mean)	1,014	-,193
Zscore (DORMS_space)	,078	1,009
Zscore (PARTNERS_num)	-,199	,476
(Константа)	,028	,053

Рис. 7: Лямбда Уилкса для дискриминантных функций:

Лямбда Уилкса

Критерий для функций	Лямбда Уилкса	Хи-квадрат	ст.св.	Значимость
От 1 до 2	,616	52,298	10	,000
2	,973	2,951	4	,566

В рамках **задачи 2.2** требовалось оценить значимость дискриминантной функции по Уилкса. Анализ показал, что статистически значима только первая функция (ее *p–value* < 0.001); в то время как вторая функция, напротив, не значима (ее *p–value* = 0.566, что > 0.005). При этом,

даже для первой функции показатель лямбды Уилкса скорее «средний»: исходя из того, что $\lambda = 0.616$, можно наблюдать умеренно сильный эффект дискриминации, где лишь около 40% межгрупповой дисперсии объясняется рассматриваемыми факторами (дохода, зарплат и проч.).

В рамках **задачи 2.3** требовалось определить относительный вклад каждой переменной в формирование классов. Это возможно, особенно потому, что данные стандартизированы, а значит коэффициенты функции можно напрямую сравнивать меж собой. Как следует из результатов анализа (*приведены на рис. 5*), наибольший вклад в формирование групп вносит показатель «ZSALARY_mean», т.е. уровень средней заработной платы преподавателей образовательных учреждений (коэфф. = 1.014). Вторым по значимости с заметными отставание следует показатель численности докторантов «ZDOC_num» (коэфф. = 0.407); вдвое слабее него — показатель «ZINCOME_per_capita» доходов образовательных организаций в пересчете на студента (коэфф. = 0.219). Площадь общежитий «ZDORMS_space» оказывает минимальное влияние на разделение групп (коэфф. = 0.078), а число предприятий–партнеров «ZPARTNERS_num» оказывает слабый отрицательный эффект (коэфф. = –0.199).

Таким образом, можно сделать вывод, что лишь финансовые показатели оказывают эффект на принадлежность ВУЗа к определенной группе по уровню среднего балла ЕГЭ абитуриентов. Научный потенциал в виде числа докторантов почти втрое слабее финансовых показателей; инфраструктурные характеристики — площадь общежитий и число–баз практик — пренебрежительно малы в контексте эффекта на дискриминацию.

В рамках **задачи 2.4** требовалось определить средние значения дискриминантной функции по группам, для чего были найдены центроиды

для каждой из трех групп (группы «1» — низкий уровень ВУЗов по ЕГЭ, «2» — средний; «3» — «высокий»).

Рис. 8: Значения дискриминантной функции в центроидах групп:

Функции в центроидах групп

Percentile Group of EGE_score	Функция	
	1	2
1	-,557	-,196
2	-,490	,204
3	1,075	-,009

Наибольшее значение (1.075 ед.) дискриминантной функции наблюдается у группы ВУЗов «3», т.е. у передовых по всем показателям образовательных организаций. Однако, важно не это, а то, что группы с «низким» и «средним» уровнями ЕГЭ имеют очень близкие значения центроидов — –0.49 и –0.56 соответственно. Это свидетельствует о том, что дискриминантная функция в большей степени отделяет «высокобалльные» ВУЗы от всех остальных, нежели качественно разделяет всю выборку на три непохожих кластера.

В рамках **задачи 2.5** требовалось указать, к каким группам были отнесены классифицируемые объекты и вероятности, с которыми исключенные на предыдущем этапе объекты входят в эти группы.

Касательно классификации наблюдений с исключенной групповой принадлежностью, анализ верно для всех трех случаев предсказывает принадлежность: к группе с «высоким» уровнем среднего балла ЕГЭ анализ отнес наблюдения №84 и №76 с вероятностями вхождения 0.61 и 0.94 соответственно, к группе со «средним» уровнем — наблюдение №115 с вероятностью 0.61, что соответствовало изначальному разбиению.

Рис. 9: Классификационная статистика:

Результаты классификации[a]

		Percentile Group of EGE_score	Предсказанная принадлежность к группе			Всего
			1	2	3	
Исходный	Количество	1	24	10	4	38
		2	16	14	8	38
		3	4	7	26	37
		Несгруппированные наблюдения	0	1	2	3
	%	1	63,2	26,3	10,5	100,0
		2	42,1	36,8	21,1	100,0
		3	10,8	18,9	70,3	100,0
		Несгруппированные наблюдения	,0	33,3	66,7	100,0

a. 56,6% исходных сгруппированных наблюдений классифицированы правильно.

Говоря же о точности классификации в целом для всех наблюдений, она оказывается скорее удовлетворительной — около 57% исходных наблюдений были классифицированы достоверно.

Стоит отметить, что наибольший процент «успеха» демонстрирует классификация для группы «3» — в ней 70% значений были помечены верно. Несколько хуже выглядит точность классификации для группы «1» — здесь около 63% наблюдений выявлены верно. В то же время, группа «2» демонстрирует наихудщую классификацию: для нее лишь 37% исходных наблюдений были отмечены верно, что можно объяснить ее близостью к первой группе по большинству значимых характеристик. Таким образом, подтверждается ранее выдвинутый тезис о слабости дискриминации выборки на три полноценных и непохожих кластера; анализ скорее выделяет группы «высокого» уровня и «все остальное».

В рамках **задачи 2.6** требовалось проверить значимость различий средних значений дискриминантной функции в группах.

Рис. 10: Вклад переменных в различия между группами:

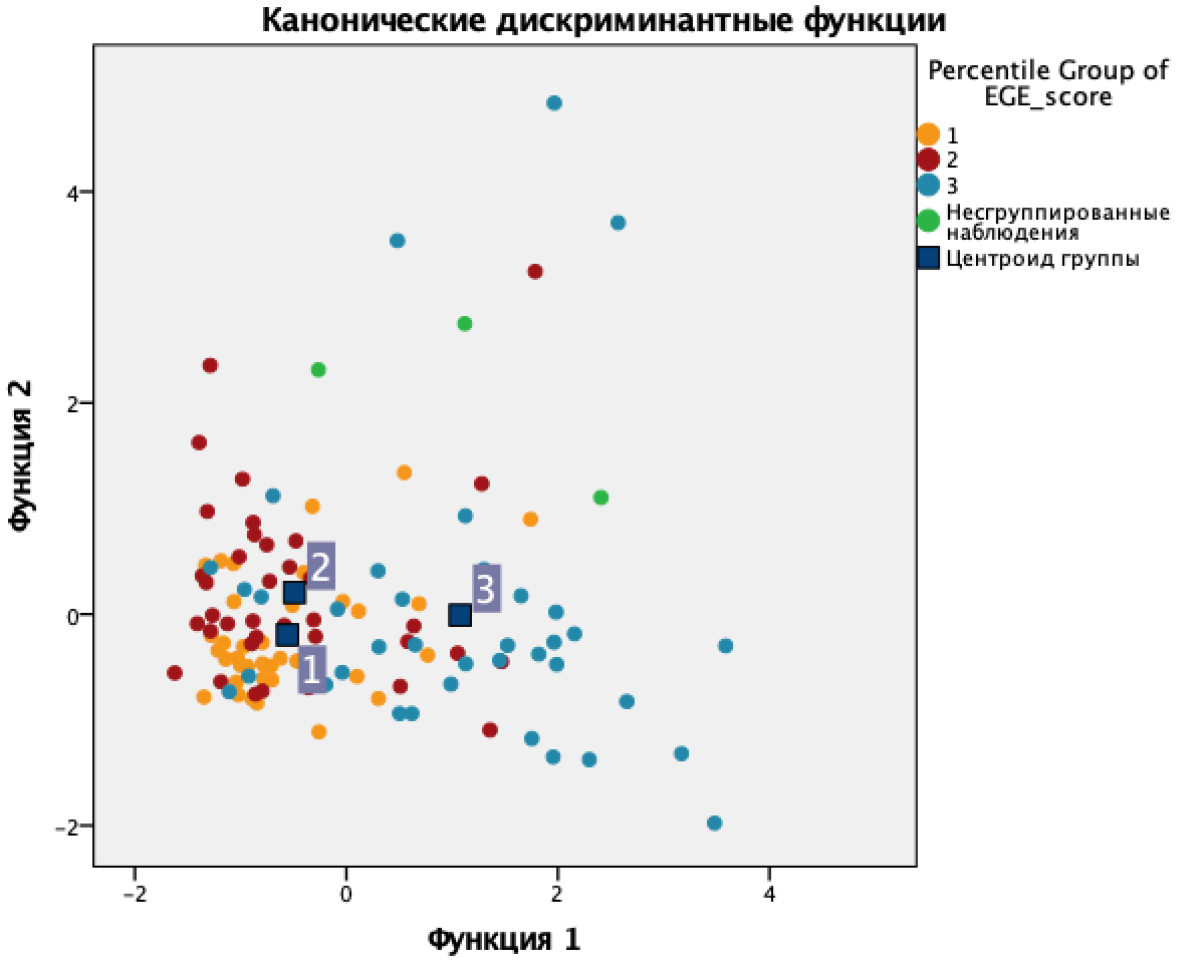
Критерии равенства групповых средних

	Лямбда Уилкса	F	ст.св.1	ст.св.2	Значимость
Zscore (INCOME_per_capita)	,865	8,581	2	110	,000
Zscore (DOC_num)	,944	3,282	2	110	,041
Zscore (SALARY_mean)	,673	26,731	2	110	,000
Zscore (DORMS_space)	,949	2,975	2	110	,055
Zscore (PARTNERS_num)	,988	,675	2	110	,511

Результаты анализа показывают, что статистически значимыми не все показатели, а только уровень заработной платы («ZSALARY_mean»), доходов на студента («ZINCOME_per_capita») и численности докторантов («ZDOC_num»), т.к. для них *p–value* < 0.005. При этом их лямбды Уилкса крайне высоки 0.673, 0.865 и 0.944 соответственно, что говорит о том, что хотя различия между группами и есть, они относительно невелики.

В рамках **задачи 2.7** требовалось оценить качество дискриминантного анализа, что фактически дублирует содержание задачи 2.5, где изучались итоги классификации наблюдений. В целом, уместно вновь отметить, что наиболее успешно модель классифицирует ВУЗы только для высокого показателя среднего балла ЕГЭ абитуриентов; кроме того стоит отметить, что реальной дискриминирующей силой обладает только первая функция. Эти выводы можно подкрепить графическим представлением выборки, из которого исходит, что кластеры «1» и «2» фактически «наложены» друг на друга, а различие уяснимо скорее по оси первой функции и только между группами «1+2» как объединенным кластером и группой «3», некоторые значения которой, впрочем, также находятся в области двух других кластеров.

Рис. 11: Графическое представление анализа:



В рамках **задачи 2.8** требовалось оценить целесообразность применения дискриминантного анализа.

В целом представляется, что такой анализ скорее целесообразен:

Во–первых, полученная модель оказывается статистически значимой ($\lambda = 0.616$; *p–value* < 0.001) и позволяет выявить факторы («ZSALARY_mean», «ZINCOME_per_capita», «ZDOC_num» — в наименьшей степени), определяющих принадлежность ВУЗов к группам по среднему баллу ЕГЭ, хотя их дискриминирующий эффект невелик.

Во–вторых, несмотря на умеренную точность классификации (ок. 57%), анализ позволяет выявить значимые различия хотя бы между ВУЗами с высоким уровнем среднего балла ЕГЭ абитуриентов и остальными организациями; кроме того — анализ справляется с классификацией и для 3 выявленных экстремальных наблюдений.

Этап 3: Дискриминантный анализ

Описание требований:

1. Выбрать зависимую переменную;
2. Построить деревья с помощью метода CHAID с различными независимыми переменными;
3. Выбрать оптимальное дерева с помощью таблицы классификации;
4. Визуализировать и интерпретировать результаты.

Использованное ПО: SPSS

Для выполнения данного этапа был выбран метод CHAID для построения деревьев; на этапе уточнения характеристик будущей классификации были заданы критерии максимального количества уровней (4), минимум наблюдений в узле–родителе (20), минимум наблюдений в узле–ребенке (10) — данные значения продиктованы объемом выборки.

Первоначальное дерево, построенное для всех трех переменных, показавших себя как статистически значимых на предыдущем этапе (SALARY_mean, INCOME_per_capita, DOC_num), имело глубину в 2 уровня; содержало 6 узлов; 4 из узлов оказались конечными.

При этом в модель были включены только две переменные: SALARY_mean и DOC_num, показатель же INCOME_per_capita не внес дополнительного вклада в классификацию и был автоматически исключен. Зависимой переменной стала переменная NEGE_score (значения [1; 2; 3]), являющаяся численным аналогом переменной EGE_category, где 1 — «низкий» уровень ВУЗа по баллу ЕГЭ, 2 —«средний», «3» — высокий.

Качество классификации составило ок. 61% на обучающей выборке; ошибка классификации = 0.388; ошибка при перекрестной проверке = 0.457. Следовательно, построение данного дерева обеспечило приемлемое качество классификации, превышающее случайное угадывание (*p* для него ≈33%), а потому его можно счесть удовлетворительным (но не высоким).

Рис. 12: Оценка точности классификации первого дерева:

Риск

Метод	Оценка	Стандартная ошибка
Повторная подстановка	,388	,045
Перекрестная проверка	,457	,046

Классификация

Наблюденные	Предсказанные			
	1	2	3	Процент правильных
1	20	10	8	52,6%
2	12	20	7	51,3%
3	1	7	31	79,5%
Общая процентная доля	28,4%	31,9%	39,7%	61,2%

Как и на предыдущем этапе, классификация для группы «3» оказалась наиболее точной — к ней были верно отнесены ок. 80% наблюдений; в то же время, для групп «1» и «2» число достоверно определенных принадлежностей ниже — 53% и 51% соответственно, что вновь говорит об относительной гомогенности этих групп.

Другое построенной дерево было выполнено с использование тех же критериев, что и первое, однако для него в качестве независимых переменных были выбраны лишь SALARY_mean и INCOME_per_capita как два показателя, обладающих большей дискриминантной способностью, продемонстрированной на предыдущем этапе.

Однако, это не улучшило модель: теперь в нее автоматически включился лишь один показатель — SALARY_mean; число всех узлов (4) и конечных (3) сократилось; а глубина уменьшилась (1) — а вместе с этим упало и качество классификации, которое теперь составило только 54% верно отнесенных наблюдений. При этом дерево вообще не смогло верно классифицировать ни одно наблюдение как принадлежащее группе «1».

Рис. 13: Оценка точности классификации второго дерева:

Риск

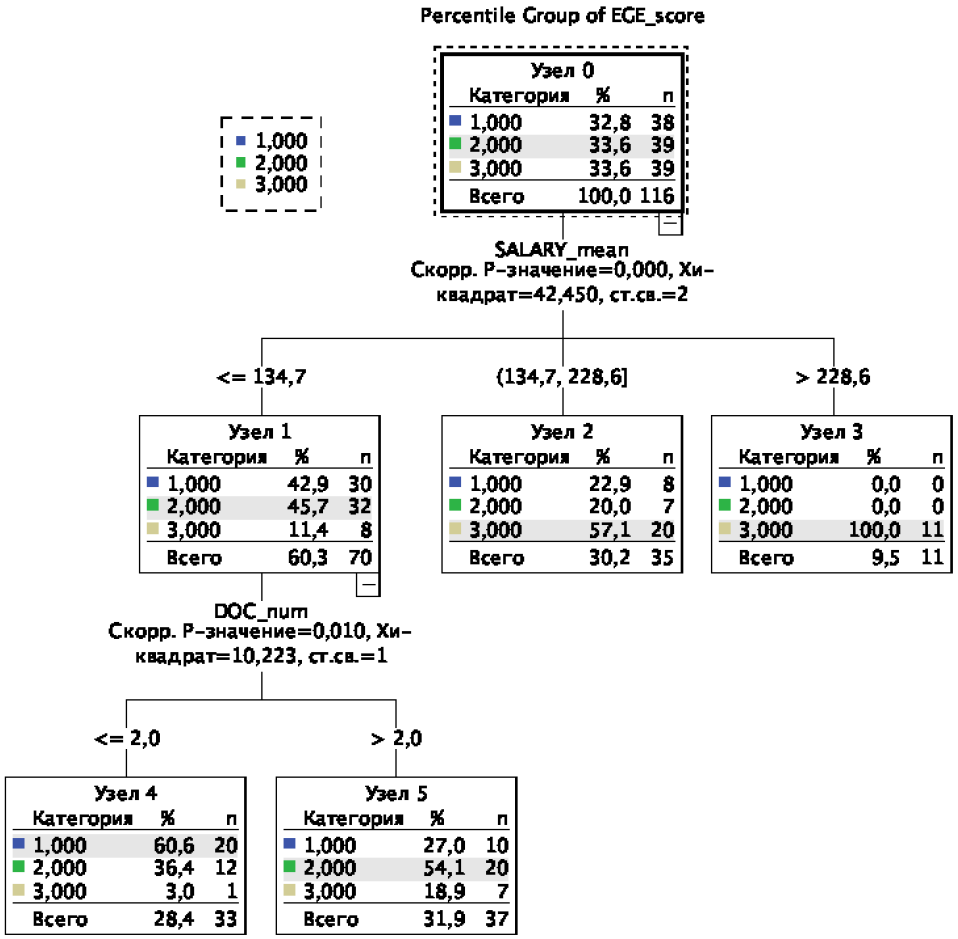
Метод	Оценка	Стандартная ошибка
Повторная подстановка	,664	,044
Перекрестная проверка	,845	,034

Классификация

Наблюденные	Предсказанные			
	1	2	3	Процент правильных
1	0	30	8	0,0%
2	0	32	7	82,1%
3	0	8	31	79,5%
Общая процентная доля	0,0%	60,3%	39,7%	54,3%

Таким образом, обоснованно привести и описать визуализацию для первого дерева:

Рис. 14: Визуализация первого дерева:



Корневой узел дерева содержит все 116 наблюдений; первое разделение выполняется по переменной SALARY_mean, для которой X^2 = 42.5, а *p–value* < 0.001, т.е. именно уровень заработной платы является главным и значимым фактором, различающим группы ВУЗов по ЕГЭ.

Модель выделила три интервала заработной платы:

до 134.7 тыс. руб. (включительно)

— **узел 1**, включивший в себя 70 наблюдений, из которых к группе «1» отнесено ок. 43% ВУЗов; к группе «2» — ок. 46% ВУЗов, а к группе «3» — ок. 11% ВУЗов, т.е. данный узел почти не содержит «высокоуровневых» образовательных учреждений.

от 134.7 тыс. руб. до 228.6 тыс. руб (включительно)

— **узел 2**, включивший в себя 25 наблюдений, из которых к группе «1» отнесено ок. 23% ВУЗов; к группе «2» — 20% ВУЗов, а к группе «3» — ок. 57% ВУЗов, т.е. данный узел содержит преимущественно образовательные учреждения с высокими показателями баллов ЕГЭ.

от 228.6 тыс. руб

— **узел 3**, включивший в себя 11 наблюдений, из которых все 100% были отнесены к группе «3», что говорит о решающей силе экстремального дохода как дискриминационного фактора для данной классификации.

Второй уровень дерева рассматривает ВУЗы с низшим уровнем зарплат по показателю DOC_num; для него X^2 = 10.2, а *p–value* = 0.01, что говорит о статистически значимой взаимосвязи предиктора и отклика.

Модель данного уровня выделила два интервала числа докторантов:

до 2 человек (включительно)

— **узел 4**, включивший в себя 33 наблюдения, из которых к группе «3» относится лишь 3% наблюдений — что, ожидаемо, свидетельствует о «низком» уровне среднего балла ЕГЭ абитуриентов тех ВУЗов, что демонстрируют финансовое и кадровое неблагополучие.

от 2 человек

— **узел 6**, включивший в себя 37 наблюдений, из которых к группе «1» отнесено 27% ВУЗов; к группе «2» — 54% ВУЗов, а к группе «3» — 19% всех ВУЗов; данное соотношение говорит о том, что при небольшом уровне зарплат, но сравнительно большем числе докторантов, образовательные учреждения демонстрируют скорее «средний» уровень показателя балла ЕГЭ абитуриентов.

Интерпретируя содержательно полученное дерево в целом, можно отметить, что уровень оплаты труда — основной фактор, определяющий принадлежность образовательных учреждений к группам, сформированным по уровню среднего балла ЕГЭ их абитуриентов. При низких значениях заработной платы дополнительное значение приобретает кадровый потенциал ВУЗов, который измеряется в числе докторантов. В целом, данная модель явно свидетельствует: чем выше заработная плата и кадровая обеспеченность ВУЗа, тем выше его вероятность быть отнесенным к группе ВУЗов с наивысшими баллами ЕГЭ поступающих — это согласуется с результатами дискриминантного анализа, т.к. в обоих случаях показатель средней заработной платы профессорско–преподавательского состава вносит наибольший вклад в разделение групп.

Отвечая на вопрос «*почему показатель INCOME_per_capita среднего дохода в пересчете на студента не вошел в модель?*» стоит отметить: в то время как дискриминантный анализ оценивает вклад каждой переменной одновременно, деревья классификации скорее задаются вопросом о том, какая переменная *сейчас* лучше всего разделит выборку. В данном случае после разделения по уровню зарплат большая часть различий между группами уже объяснилась; добавление доходов бы не привнесло бы новой информации — отчасти потому, что доходы и зарплаты связаны между собой, а значит, имеет место дублирование, которого нет с докторантами.

Этап 4: Расщепление смеси

Описание требований:

1. Выяснить, сколько распределений скрыто в данных;
2. Установить, какие параметры имеет каждое распределение;
3. Найти, какова доля каждого распределения в общей совокупности;
4. Определить, к какому распределению относится конкретное наблюдение.

Использованное ПО: Microsoft Excel

Если предположить, что данные описываются смесью логнормальных распределений, то каждое наблюдение можно отнести к одной из нескольких компонент смеси распределений, каждая из которых характеризуется ср. логарифмом показателя, степенью разброса значений и долей в общей совокупности.

После нахождения $ln(X)$ для каждого наблюдения, была построена модель смеси из четырёх логнормальных распределений. При этом для каждой компоненты смеси определялись три параметра: μ — математическое ожидание логарифма признака, σ — стандартное отклонение логарифма признака, q — доля компоненты в общей смеси.

Начальные значения параметров были рассчитаны по квартилям логарифмированных данных. Затем параметры смеси были уточнены с помощью функции Excel «Поиск решения». В качестве целевой функции использовалась сумма логарифмов плотности смеси распределений. Целевая функция максимизировалась, так как применялся метод максимального правдоподобия. При оптимизации были заданы ограничения: стандартные отклонения σ должны быть не меньше 0,001, доли q должны быть неотрицательными, а сумма всех долей q должна равняться 1. Для решения использовался нелинейный метод ОПГ.

Рис. 15: Пример расчетов:

X	Ln(x)	ln f(x)	№	μ	σ	q
24,41	3,1949929	-4,974094	1	1,348917292	1,584339361	0,1187781
15,47	2,7389027	-4,691946	2	3,318341239	0,826400631	0,3217853
37,18	3,615771	-5,47129	3	4,604847042	0,039522069	0,2574619
24,14	3,1838702	-4,964145	4	4,634538858	0,229067983	0,3019747
86,36	4,4585246	-5,238214				Сумма q

Описывая полученные компоненты, можно отметить:

Компонента 1 содержит 11.9% наблюдений и имеет наибольший разброс ($\sigma = 1.58$), т.е. является наиболее неоднородной группой;

Компонента 2 содержит 32.2% наблюдений, средний уровень признака X и умеренный разброс;

Компонента 3 содержит 25.7% наблюдений и является практически однородной группой, демонстрируя очень маленькое $\sigma = 0.04$;

Компонента 4 содержит 30.2% наблюдений и близка к компоненте 3 по среднему уровню, но демонстрирует более широкий разброс.

Далее было выполнено отнесение отдельных наблюдений (№ 7, 12, 17, 19 — номера соответствуют позиции каждого из соавторов в учебном списке группы) на основе того, насколько хорошо значение данного наблюдения соответствует параметрам каждой компоненты с учетом ее доли в общей совокупности; наблюдение относилось к той компоненте, для которой эта вероятность была максимальной.

Для наблюдения №7 максимальная вероятность принадлежности соответствует второй компоненте смеси; для наблюдения №12 максимальная вероятность принадлежности соответствует четвертой компоненте смеси; для наблюдения №18 максимальная вероятность принадлежности соответствует третьей компоненте смеси; для наблюдения №19 максимальная вероятность принадлежности соответствует второй компоненте смеси.

Рис. 15: Расчет вероятности отнесения наблюдений к компонентам:

P1	P2	P3	P4	Компонента
F5;0))	0,9101264	7,25E-276	8,2743E-09	2
0,1435011	0,8564989	0	4,992E-15	2
0,0687236	0,9311059	1,67E-135	0,00017046	2
0,0907159	0,9092841	3,05E-280	6,0983E-09	2
0,009504	0,1307814	0,0059836	0,85373104	4
0,0058502	0,0682823	0,0126243	0,91324319	4
0,1378646	0,8621354	0	1,6326E-14	2
0,003178	0,0420576	0,5637635	0,39100088	3
0,0011413	0,0145747	0,8197378	0,16454614	3
0,292406	0,707594	0	2,1107E-24	2
0,0073496	0,0993722	0,1148363	0,77844198	4
0,0073765	0,0997518	0,1125882	0,78028341	4
0,0021198	0,0261931	0,6430578	0,32862925	3
0,1198838	0,8801162	0	1,0506E-12	2
0,0021113	0,0260918	0,6445319	0,32726492	3
0,0011537	0,0147735	0,8191806	0,16489212	3
0,0856523	0,9143476	5,51E-253	4,0928E-08	2
0,0028799	0,0352574	0,5107787	0,45108398	3
0,0901824	0,9098176	1,77E-277	7,3949E-09	2
0,0218823	0,3194702	4,232E-14	0,65864745	4

Наконец, была построена диаграмма для сравнения эмпирического распределения данных с теоретическим. Видно, что основная часть значения сосредоточена в интервале 80–90, т.е. там, где наибольший вклад вносят третья и четвертая компоненты смеси. В диапазоне низких значений преобладает вторая компонента; первая же, ожидаемо, имеет небольшой вклад и описывает сравнительно мало наблюдений. В целом сумма теоретических компонент скорее хорошо воспроизводит общую форму эмпирического распределения, что подтверждает достоверность модели смеси распределений.

Рис. 16: Диаграмма для эмпирического и теоретического сравнения:

